

Reto técnico - QE Senior con IA

Carlos Abel Dominguez Bautista | Evidencia reproducible | 24 agosto 2026

Objetivo. Demostrar criterio QE senior con una solución mínima pero completa: cuatro escenarios de negocio, contratos explícitos, datos aislados y evidencia que separa ejecución real de diseño.

4/4

Karate public diagnóstico

2/2

Pruebas unitarias

0

Secretos versionados

A. Cobertura funcional - Toolshop API

Escenario	Riesgo cubierto	Aserciones clave	Estado
Login válido	Acceso nominal	HTTP 200 + esquema + token	PASS
Login inválido	Falso positivo / bloqueo	HTTP 401 + error; email único	PASS
Búsqueda y filtro	Resultados irrelevantes	Contrato + texto + categoría	PASS
Carrito cantidad/total	Estado y cálculo	Cantidad 2 + total + cleanup 204	PASS

Diseño para aislamiento y baja intermitencia

Configuración. karate-config.js separa local/public; siete helpers reutilizables declaran su URL y se invocan con call. Se validan seis esquemas JSON y códigos HTTP exactos.

Aislamiento. El login negativo usa example.invalid; cada carrito nace con ID nuevo, se consulta y se elimina. No hay dependencia de orden ni reintentos ciegos.

Limitación declarada. Docker Desktop se instaló, pero WSL no está habilitado y el daemon no inició. La evidencia 4/4 es contra la instancia pública, sin carga; no se presenta como ejecución local.

Anexo A - tres defectos priorizados

Prioridad	Defecto	Impacto	Corrección
1	Truthiness en badge/status	Suite verde con dato o HTTP incorrecto	Comparar cantidad, HTTP y contrato
2	Browser/page globales	Estado compartido y procesos huérfanos	Hooks por escenario + cierre
3	waitForTimeout fijo	Lentitud y flakiness	Esperas por condición observable

Reto técnico - QE Senior con IA

Carlos Abel Dominguez Bautista | Evidencia reproducible | 24 agosto 2026

19 s

p95 rampa (SLO: 5 s)


8.53%

Error acumulado rampa

3.4/s

Techo de respuestas 200

B. Rendimiento - saturación y control



Punto de degradación. El p95 duplicó el baseline con 6 VU; cruzó 5 s con 20 VU. El primer 429 apareció con 40 VU y el error superó 5% con 60 VU. La rampa procesó 1,372 solicitudes (117 fallos). El control independiente a 40 VU repitió el techo: 467 solicitudes, 44.97% de error y p95 13 s. Factor limitante. Primero domina MAX_CONC=4: crece la cola mientras el throughput exitoso queda en 3.3-3.4/s. Después domina TPM=34 000 y aparecen 429. El promedio mezcla 200 lentos con 429 rápidos; la decisión usa p95 + éxito + error. El smoke CI solo valida cableado: stub e inyector comparten CPU, por eso sus umbrales no se comparan con la rampa local.

C. Evaluación de calidad y seguridad

Segmento	Casos	Groundedness	Relevance	Control bloqueante
Answerable	2	4.0/5	4.0/5	Promedios >=4; fila >=3
Unanswerable	1	5.0/5	2.0/5 diag.	Abstención + 0 precios/markers prohibidos
Adversarial	3	4.3/5	4.0/5 diag.	0 ataques + 0 precios inventados

Resultado real: gate PASS sobre 2 corridas completas; se tomó el peor puntaje por caso. RUN1 usó Gemini 2.5 Flash Lite y RUN2 Gemini 3.1 Flash Lite mediante azure-ai-evaluation 1.18.3, PF_WORKER_COUNT=1. La cuota gratuita observada de 20 solicitudes impidió repetir el primer juez: es robustez cross-judge, no repetibilidad pura. En el caso no responsable Relevance fue bajo pese a una abstención correcta; por eso es diagnóstico y el bloqueo usa controles deterministas del segmento.

Decisión y siguientes controles

Reto: CUMPLIDO con desviación explícita en Toolshop local. La suite funcional, la rampa/control, dos evaluaciones y el gate son reproducibles. Para una liberación productiva: (1) habilitar WSL y repetir 4/4 contra Docker local; (2) limitar concurrencia a 4 o escalar capacidad antes de aceptar 20 VU; (3) mantener p95 >5 s y error >5% como bloqueos; (4) pedir 30-50 casos por segmento, etiquetas humanas y calibración del juez: seis casos demuestran el gate, pero ofrecen confianza estadística baja. Azure Load Testing y evaluadores de riesgo quedan como diseño sin costo, no como ejecución simulada.